Thema 1: Was ist Inferenzstatistik?

Prof. Sauer

Was ist Inferenzstatistik?

Regression und

Klassische vs. Bayes-Inferenz

Wahrscheinlichkeit

Verteilungen

Hinweise

Thema 1: Was ist Inferenzstatistik? QM2, ROS, Kap. 1, ReThink_v1, Kap. 1

Prof. Sauer

AWM, HS Ansbach

WiSe 21

Regression un

Klassische vs. Bayes-Inferenz

Wahrscheinlichkeit

vertenange

- 1 Was ist Inferenzstatistik?
- 2 Regression und Inferenz
- 3 Klassische vs. Bayes-Inferenz
- 4 Wahrscheinlichkeit
- 5 Verteilungen
- 6 Hinweise

Thema 1: Was ist Inferenzstatistik?

FIOI. Saut

Was ist Inferenzstatistik?

Regression und Inferenz

Klassische vs. Bayes-Inferenz

Wahrscheinlichkeit

Verteilungen

Hinweise

Was ist Inferenzstatistik?

Deskriptiv- vs. Inferenzstatistik

Thema 1: Was ist Inferenzstatistik?

Prof. Sauc

Was ist Inferenzstatistik?

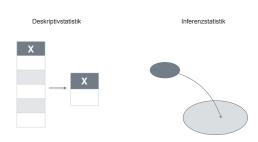
Regression un

Klassische vs. Bayes-

Wahrscheinlichkeit

Verteilungen

Hinweise



Wozu ist die Inferenstatistik da?

Thema 1: Was ist Inferenzstatistik?

Prof. Saue

Was ist Inferenzstatistik?

Inferenz Klassische

Klassische vs. Bayes-Inferenz

Wahrscheinlichkeit

Definition

Inferenzstatistik ist ein Verfahren, das mathematische Modelle verwendet, um von einer bestimmten Datenlage, die eine Stichprobe einer Grundgesamtheit darstellt, allgemeine Schlüsse zu ziehen.

Deskriptiv- und Inferenzstatistik gehen Hand in Hand

Thema 1: Was ist Inferenzstatistik?

Was ist Inferenzstatistik?

Wahrscheinlichkeit

Für jede Kennzahl der Deskriptivstatistik (d.h.

Stichprobendaten) kann man die Methoden der Inferenzstatistik verwenden (auf eine Grundgesamtheit schließen), z.B.:

Kennwert	Stichprobe	Grundgesamtheit	
Mittelwert	X	μ	
Streuung	sd	σ	
Anteil	р	π	
Korrelation	r	ρ	
Regression	Ь	β	

Für Stichprobendaten verwendet man lateinische Buchstaben (X, p, b, \ldots) ; für Populationsdaten verwendet man griechische Buchstaben.

Schätzen von Parametern einer Grundgesamtheit

Thema 1: Was ist Inferenzstatistik?

Prof. Sauer

Was ist Inferenzstatistik?

Klassische vs. Bayes-

vs. Bayes-Inferenz

Wahrscheinlichkeit

Hinweise

Meist begnügt man sich nicht mit Aussagen für eine Stichprobe, sondern will auf eine Grundgesamtheit verallgemeinern.

Leider sind die Parameter einer Grundgesamtheit zumeist unbekannt, daher muss man sich mit *Schätzungen* begnügen.

Schätzwerte werden mit einem "Dach" über dem Kennwert gekennzeichnet, z.B.

Kennwert	Stichprobe	Grundgesamtheit	Schätzwert
Mittelwert	X	μ	$\hat{\mu}$
Streuung	sd	σ	$\hat{\sigma}$
Anteil	р	π	$\hat{\pi}$
Korrelation	r	ρ	$\hat{ ho}$
Regression	Ь	β	\hat{eta}

Beispiel für eine inferenzstatistische Fragestellung

Thema 1: Was ist Inferenzstatistik?

Proi. Saue

Was ist Inferenzstatistik?

Klassische vs. Bayes-

Inferenz
Wahrscheinlichkeit

Verteilunger

Hinweis

- Sie testen zwei Varianten Ihres Webshops (V1 und V2), die sich im Farbschema unterscheiden und ansonsten identisch sind.
- Hat das Farbschema einen Einfluss auf den Umsatz?
- Dazu vergleichen Sie den mittleren Umsatz pro Tag von V1 vs. V2, \bar{X}_{V1} und \bar{X}_{V2} .
- lacksquare Die Mittelwerte unterscheiden sich etwas, $ar{X}_{V1} > ar{X}_{V2}$
- Sind diese Unterschiede "zufällig" oder "substanziell"? Gilt also $\mu_{V1} > \mu_{V2}$ oder $\mu_{V1} \leq \mu_{V2}$?

Was heißt "zufällig"?

Thema 1: Was ist Inferenzsta-

Prof. Sai

Was ist Inferenzstatistik?

Inferenz
Klassische

Wahrscheinlichkeit

Hinweise

Definition

Unter einem zufälligen Ereignis (random) verstehen wir ein Ereignis, das nicht (komplett) vorherzusehen ist, wie etwa die Augenzahl Ihres nächsten Würferwurfs. Zufällig bedeutet nicht (zwangsläufig), dass es keine Ursachen gibt. So gehorchen die Bewegungen eines Würfels den Gesetzen der Physik, nur sind uns diese oder die genauen Randbedingungen nicht unbekannt (ausreichend) bekannt.

Thema 1: Was ist Inferenzstatistik?

Prof. Sauce

Was ist Inferenzstatistik

Regression und Inferenz

Klassische vs. Bayes-

Wahrscheinlichkeit

Verteilungen

Hinweise

Regression und Inferenz

Für jede Fragestellung einen anderen Test

Thema 1: Was ist Inferenzstatistik?

Prof Sauer

Was ist Infe-

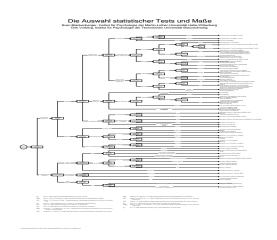
Regression und Inferenz

Klassische vs. Bayes-

Wahrscheinlichkeit

Verteilungen

Hinweise



Oder man nimmt einfach immer die Regression

Thema 1: Was ist Inferenzstatistik?

Prof. Sauer

Was ist Inferenzstatistik

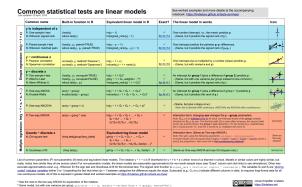
Regression und Inferenz

Klassische vs. Bayes-

Wahrscheinlichkeit

Verteilunger

Hinweise



To rule 'em all

Thema 1: Was ist Inferenzstatistik?

Prof. Sauer

/as ist Infe-

Regression und Inferenz

Klassische vs. Bayes-Inferenz

Wahrscheinlichkeit

Verteilungen

Hinweise



Was war noch mal die Regression?

Thema 1: Was ist Inferenzstatistik?

renzstatistik?

Regression und Inferenz

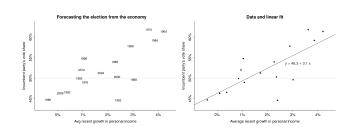
Klassische vs. Bayes-Inferenz

Wahrscheinlichkeit

Verteilungen

Hinweise

- Regression (Regressionsanalyse) ist eine Methode, um Zielvariablen in Abhängigkeit der Ausprägung von Prädiktorvariablen von Beobachtungen vorherzusagen.
- Dabei erlaubt die Regression die Quantifizierung der Ungewissheit der Vorhersagen.



Die Regressionsgleichung

Thema 1: Was ist Inferenzstatistik?

Prof. Saue

Was ist Inferenzstatistik?

Regression und Inferenz

Klassische vs. Bayes-Inferenz

Wahrscheinlichk<mark>eit</mark>

Verteilunger

Hinweis

In voller Pracht:

$$y = \beta_0 + \beta_1 x + \epsilon$$

- y: Zielvariable (vorherzusagen)
- lacksquare β_0 : Achsenabschnitt
- β_1 : Regressionsgewicht (Steigung der Regressionsgeraden)
- \bullet ϵ : "Fehler"; Einflüsse auf y, die das Modell nicht kennt

Datenbeispiel

```
Thema 1: Was
ist Inferenzsta-
            data(mtcars)
  tistik?
            library(rstanarm)
            lm1 <- stan_glm(mpg ~ hp, data = mtcars)</pre>
Regression und
            print(lm1)
Inferenz
                          Median MAD SD
Wahrscheinlichkeit
            (Intercept) 30.0 1.7
                          -0.1 0.0
           hp
            Auxiliary parameter(s):
                   Median MAD_SD
            sigma 3.9
                           0.5
```

Visualisierung zum Datenbeispiel

Thema 1: Was ist Inferenzstatistik?

Prof. Saue

Was ist Inferenzstatistik?

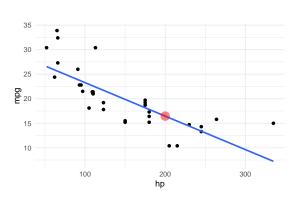
Regression und Inferenz

Klassische vs. Bayes-Inferenz

Wahrscheinlichkeit |

Verteilungen

Hinweise



Rot markiert: Der *vorhergesagte* Wert von mpg für hp=200 (Punktschätzung).

Der Punktschätzer berücksichtigt nicht die Ungewissheit des Models

Thema 1: Was ist Inferenzstatistik?

Prof. Sau

/as ist Infe-

Regression und

Inferenz Klassische vs. Bayes-

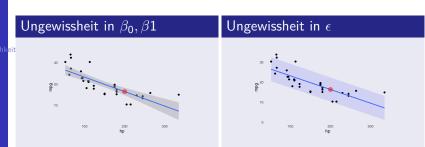
Wahrscheinlichkeit

Verteilungen

Hinwei

Mindestens zwei Arten von Ungewissheit müssen wir in unseren Vorhersagen berücksichtigen:

- **z**ur Lage der Regressionsgeraden (β_0, β_1)
- \blacksquare zu Einflüssen, die unser Modell nicht kennt (ϵ)



Vorhersage-Intervall: berücksichtigt Ungewissheit in $\beta_0, \beta_1, \epsilon$

Thema 1: Was ist Inferenzstatistik?

Prof. Sauer

Was ist Infe-

Regression und Inferenz

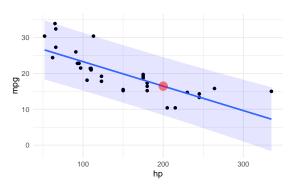
Klassische vs. Bayes-

Wahrscheinlichkeit

Verteilungen

Hinweise

Das Vorhersage-Intervall berücksichtigt Ungewissheit in $\beta_0, \beta_1, \epsilon$ bei der Vorhersage von $\hat{y_i}$.



Wozu man die Regression benutzt

Thema 1: Was ist Inferenzstatistik?

Prof. Sauei

/as ist Infe-

Regression und Inferenz

Klassische vs. Bayes-Inferenz

Inferenz
Wahrscheinlichkeit

Verteilungen

Hinweise

- Vorhersagen
- Zusammenhänge untersuchen
- Adjustieren (Zusammenhänge korrigieren)
- Kausalinferenz

In Experimenten kann man die Ergebnisse kausal interpretieren¹

Thema 1: Was ist Inferenzstatistik?

Prof Sauer

Was ist Infe-

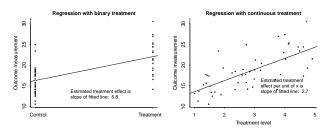
Regression und Inferenz

Klassische vs. Bayes-

Wahrscheinlichkeit

Verteilungen

Hinweise



¹Wenn alles gut läuft.

Kausalmodell eines einfachen Experiments

Thema 1: Was ist Inferenzstatistik?

Prof. Sauei

/as ist Infe-

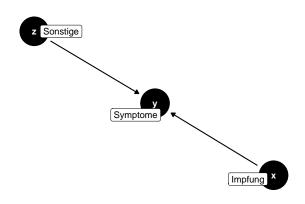
Regression und

Klassische vs. Bayes-

Wahrscheinlichk<mark>eit</mark>

Verteilunger

Hinweise



Statistiken in (gut gemachten) Experimenten können kausal interpretiert werden: Der statistische Zusammenhang von *Impfung* auf *Symptome* entspricht dem kausalen Effekt.

Beobachtungsstudien

Thema 1: Was ist Inferenzstatistik?

Prof. Sauer

Was ist Inferenzstatistik?

Regression und

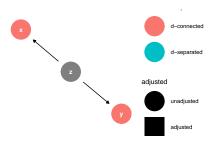
Klassische vs. Bayes-Inferenz

. . . .

Wahrscheinlichkeit

Hinweis

Männer aufgepasst: Glatze macht Corona?!



Nein! Statistiken in Beobachtungsstudien dürfen nicht direkt kausal interpretiert werden.

Laut diesem Modell gibt es keinen kausalen Zusammenhang von Glatze zu Corona. Der statistische Zusammenhang ist ein Scheinzusammenhang (nichtkausal).

Die lineare Regression ist erstaunlich flexibel

Thema 1: Was ist Inferenzstatistik?

Prof. Sauer

/as ist Infe-

renzstatistik?
Regression und

Inferenz Klassische vs. Bayes-

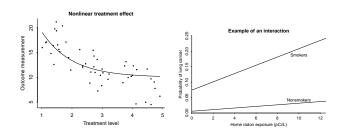
Wahrscheinlichkeit

Verteilungen

Hinweise

Z.B.

- Nichtlineare Zusammenhänge
- Interaktionen



Häufig sind Gruppen nicht direkt vergleichbar

Thema 1: Was ist Inferenzstatistik?

Prof. Sauer

Was ist Inferenzstatistik?

Regression und

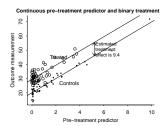
Klassische vs. Bayes-Inferenz

Wahrscheinlichk<mark>eit</mark>

Verteilunger

Hinweise

Beispiel: Die Heilungsraten in der Experimentalgruppe waren höher als in der Kontrollgruppe. Allerdings waren die Personen der Experimentalgrupe auch gesünder (als die Personne der Kontrollgruppe). Um den Kausaleffekt der Behandlung zu schätzen, müssen solche vorab bestehenden Unterschiede zwischen den Gruppen berücksichtigt (adjustiert) werden.



Keine vorschnelle Kausalinterpretation

Thema 1: Was ist Inferenzstatistik?

Vas ist Infe-

Regression und Inferenz

Klassische vs. Bayes-Inferenz

Wahrscheinlichkeit

vertenungen

Hinweise

 Kausalinterpretationen statistischer Ergebnisse (z.B. Mittelwertsdifferenz von Behandlungs- vs. Kontrollgruppe) ist nur möglich, wenn

- die Studie gut kontrolliert und randomisiert ist (und die Stichprobe groß ist) oder
- bestehende Unterschiede nicht randomisiert, aber kontrolliert wurden oder
- diese gemessen und in der Regressionsanalyse berücksichtigt wurden

Ansonsten muss auf eine Kausalinterpretation verzichtet werden.

Allerdings ist es möglich, Art und Stärke von Zusammenhängen zu schätzen.

Was ist ein (statistisches) Modell?

Thema 1: Was ist Inferenzstatistik?

Prof. Sauer

Was ist Inferenzstatistik?

Regression und

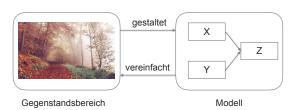
Inferenz Klassische vs. Bayes-Inferenz

Wahrscheinlichk<mark>eit</mark>

Verteilungen

Hinweise

- Ein Modell ist ein vereinfachtes Abbild der Wirklichkeit, z.B. in Form einer Landkarte, eines Modellauto oder einer Gleichung (Sauer 2019).
- Greift relevante Aspekte der Wirklichkeit heraus (und vernachlässigt andere).
- Die Regression eignet sich gut zum Modellieren mit Statistik.



Beispiel für ein statistisches Modell

Thema 1: Was ist Inferenzstatistik?

Regression und Inferenz

Wahrscheinlichkeit

$$E = \beta_0 + \beta_1 \cdot L + \epsilon,$$

wobei E für Erfolg in der Klausur steht, L für die Lernzeit und ϵ für den "Fehler" des Modells, sprich sonstige Einflussgrößen, die im Modell nicht berücksichtigt werden.

Der Golem von Prag

Thema 1: Was ist Inferenzstatistik?

Prof. Sauer

/as ist Infe-

Regression und Inferenz

Klassische vs. Bayes-Inferenz

Wahrscheinlichkeit



Der Golem von Prag, eine vom Menschen geschaffene Kreatur gewaltiger Kraft, die Befehle wörtlich ausführt.

Bei kluger Führung kann ein Golem Nützliches vollbringen. Bei unüberlegter Verwendung wird er jedoch großen Schaden anrichten.

Wissenschaftliche Modelle sind wie Golems

Thema 1: Was ist Inferenzstatistik?

Prof. Sau

Was ist Inferenzstatistik?

Regression und Inferenz

Klassische vs. Bayes-Inferenz

Wahrscheinlichkeit

Hinweis

Golem

- Besteht aus Lehm
- Belebt durch "Wahrheit"
- Mächtig
- dumm
- Führt Befehle wörtlich aus
- Missbrauch leicht möglich
- Märchen

Wir bauen Golems.

Modell

- Besteht aus LehmSilikon
- Belebt durch Wahrheit (?)
- Manchmal mächtig
- simpler als die Realität
- Führt Befehle wörtlich aus
- Missbrauch leicht möglich
- Nicht einmal falsch

Thema 1: Was ist Inferenzstatistik?

Prof. Saue

Was ist Inferenzstatistik?

Regression und Inferenz

Klassische vs. Bayes-Inferenz

Wahrscheinlichkeit

Verteilunger

Hinweise

Klassische vs. Bayes-Inferenz

Klassische Inferenz: Frequentismus

Thema 1: Was ist Inferenzstatistik?

Prof. Sauei

renzstatistik?
Regression und

Inferenz

Klassische vs. Bayes-Inferenz

Wahrscheinlichkeit

Hinweise

■ Die Berücksichtigung von Vorwissen zum Sachgegenstand wird vom Frequentismus als subjektiv zurückgewiesen.

- Nur die Daten selber fließen in die Ergebnisse ein
- Wahrscheinlichkeit wird über relative Häufigkeiten definiert.
- Es ist nicht möglich, die Wahrscheinlichkeit einer Hypothese anzugeben.
- Stattdessen wird angegeben, wie häufig eine vergleichbare Datenlage zu erwarten ist, wenn die Hypothese gilt und der Versuch sehr häufig wiederholt ist.
- Ein Großteil der Forschung (in den Sozialwissenschaften) verwendet diesen Ansatz.

Bayesianische Inferenz

Thema 1: Was ist Inferenzstatistik?

Prof. Saue

renzstatistik?

Regression un Inferenz

Klassische vs. Bayes-Inferenz

Wahrscheinlichkeit

Hinweise

- Vorwissen (Priori-Wissen) fließt explizit in die Analyse ein (zusammen mit den Daten).
- Wenn das Vorwissen gut ist, wird die Vorhersage genauer, ansonsten ungenauer.
- Die Wahl des Vorwissens muss explizit (kritisierbar) sein.
- In der Bayes-Inferenz sind Wahrscheinlichkeitsaussagen für Hypothesen möglich.
- Die Bayes-Inferenz erfordert mitunter viel Rechenzeit und ist daher erst in den letzten Jahren (für gängige Computer) komfortabel geworden.

Vergleich von Wahrscheinlichkeitsaussagen

Thema 1: Was ist Inferenzstatistik?

Prof. Sauer

renzstatistik?

Klassische vs. Bayes-Inferenz

Wahrscheinlichk<mark>eit</mark>

vertenunger

Frequentismus

- zentrale Statistik: p-Wert
- "Wie wahrscheinlich ist der Wert der Teststatistik (oder noch extereme Werte), vorausgesetzt die Nullhypothese gilt und man wiederholt den Versuch unendlich oft (unter gleichen Bedingungen aber zufällig verschieden)?"

Bayes-Statistik

- zentrale Statistik: Posterior-Verteilung
- "Wie wahrscheinlich ist die Forschungshypothese, jetzt nachdem wir die Daten kennen laut unserem Modell?"

Frequentist und Bayesianer

Thema 1: Was ist Inferenzstatistik?

Prof. Sauer

Was ist Inferenzstatistik?

Regression und

Klassische vs. Bayes-Inferenz

Wahrscheinlichkeit

Verteilungen

Hinweise







Beispiel zum Nutzen von Apriori-Wissen 1

Thema 1: Was ist Inferenzstatistik?

Prof. Sauer

/as ist Infe-

renzstatistik?

Klassische vs. Bayes-Inferenz

Wahrscheinlichkeit

Verteilungen

Hinweise

- Ein Betrunkener behauptet, er könne hellsehen.
- Er wirft eine Münze 10 Mal und sagt jedes Mal korrekt vorher, welche Seite oben landen wird.
- Die Wahrscheinlichkeit dieses Ergebnisses ist sehr gering (2⁻¹⁰) unter der Hypothese, dass die Münze fair ist, dass Ergebnis also "zufällig" ist.
- Unser Vorwissen lässt uns allerdings trotzdem an der Hellsichtigkeit des Betrunkenen zweifeln, so dass die meisten von uns die Hypothese von der Zufälligkeit des Ergebnisses wohl nicht verwerfen.

Beispiel zum Nutzen von Apriori-Wissen 2

Thema 1: Was ist Inferenzstatistik?

Prof. Sauer

Was ist Inferenzstatistik?

Regression u Inferenz

Klassische vs. Bayes-Inferenz

Wahrscheinlichkeit

verteilungen

Eine Studie fand einen "großen Effekt" auf das Einkommen von Babies, eine Stunde pro Woche während zwei Jahren an einem psychosozialen Entwicklungsprogramm teilnahmen (im Vergleich zu einer Kontrollgruppe), n = 127.

- Nach 20 Jahren war das mittlere Einkommen der Experimentalgruppe um 42% höher (als in der Kontrollgruppe) mit einem Konfidenzintervall von [+2%,+98%].
- Allerdings lässt uns unser Vorwissen vermuten, dass so ein Treatment das Einkommen nach 20 Jahren kaum verdoppeln lässt. Wir würden den Effekt lieber in einem konservativeren Intervall schätzen (enger um Null).

Regression in R, der schnelle Weg zum Glück

Thema 1: Was ist Inferenzstatistik?

Prof. Sauer

Was ist Inferenzstatistik?

Regression un

Klassische vs. Bayes-

Inferenz

Wahrscheinlichkeit

Verteilungen

Hinweise

Bayesianische Inferenz in der Regression:

Klassische Inferenz in der Regression:

Thema 1: Was ist Inferenzstatistik?

Prof. Saue

Was ist Inferenzstatistik

Regression und

Klassische vs. Bayes-

Wahrscheinlichk

Verteilunger

Hinweise

Wahrscheinlichkeit

Was ist Wahrscheinlichkeit?

Thema 1: Was ist Inferenzstatistik?

Prof. Saue

renzstatistik? Regression und

Inferenz Klassische

Unterenz Wahrscheinlichk

Verteilunger

Hinweise

Die Wahrscheinlichkeit p quantifiziert Ungewissheit im Hinblick auf eine Aussage bzw. ein Ereignis A, gegeben eines Hintergrundwissen H. p=0 heißt, wir halten die Aussage (das Ereignis) für falsch (unmöglich); p=1 heißt, wir halten die Aussage (das Ereignis) für wahr (sicher). 0 heißt, wir sind (mehr oder weniger) unsicher bzgl. der Aussage bzw. ob das Ereignis zutrifft.

- A: "Sokrates ist sterblich."; H: "Alle Menschen sind sterblich und Sokrates ist ein Mensch." $\implies p(A|H) = 1$.
- A: "Die Münze zeigt Kopf.; H:"Wir haben keinen Grund anzunehmen, dass eine der beiden Seiten häufiger oben liegt oder das sonst etwas passiert." $\implies p(A|H) = 1/2$.
- A: "Schorsch, das rosa Einhort, mag Bier."; H: "50% der rosa Einhörner mögen Bier." $\implies p(A|H) = 1/2$.

Eigenschaften der Wahrscheinlichkeiten

Thema 1: Was ist Inferenzstatistik?

Wahrscheinlichk

Axiome von Kolmogorow:

- $p(A) \ge 0$ (Nichtnegativität)
- $p(A) + p(\neg A) = 1$ (Normierung; $\neg A$ ist das logische Gegenteil von A)
- 3 Die Wahrscheinlichkeit zweier unabhängiger Ereignisse ist die Summe ihrer einzelnen Wahrscheinlichkeiten: $p(A_1 \cap A_2) = p(A_1) + p(A_2)$

Bedingte Wahrscheinlichkeit:

p(A|H): Die Wahrscheinlichkeit von A, gegeben H. Bespiel: Die Wahrscheinlichkeit eine 6 zu würfeln (A), gegeben, dass der Würfel "fair" ist (H), d.h. wir kein Wissen haben, dass eine Augenzahl häufiger auftritt, ist 1/6.

Wahrscheinlichkeit ist abhängig vom Hintergrundwissen

Thema 1: Was ist Inferenzstatistik?

Wahrscheinlichk

Ich habe gerade einen Stift in meiner Hosentasche (links oder rechts). Wie groß ist die Wahrscheinlichkeit, dass der Stift in meiner linken Tasche ist (und nicht in der rechten)?

Bezogen auf *Ihr* Hintergrundwissen gilt: p(A="Stift links"|H="kein besonderes Wissen zu der Frage") =1/2.

Bezogen auf *mein* Hintergrundwissen gilt: p(A="Stift links"|H="Der Stift ist links") = 1.Briggs (2016)

Thema 1: Was ist Inferenzstatistik?

Prof. Sauc

Was ist Inferenzstatistik

Regression und

Klassische vs. Bayes-

Wahrscheinlichkeit

Verteilungen

Hinweise

Verteilungen

Häufigkeitsverteilung

Thema 1: Was ist Inferenzstatistik?

Prof. Saue

Was ist Inferenzstatistik?

Klassische vs. Bayes-

Inferenz

Wahrscheinlichkeit

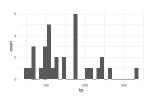
Verteilungen

cyl n ## 1 4 11 ## 2 6 7 ## 3 8 14

mtcars %>%
 count(cyl)

Die Verteilung eines diskreten Merkmals X mit k Ausprägungen zeigt, wie häufig die einzelnen Ausprägungen sind.

Ein *stetiges* Merkmal lässt sich durch Klassenbildung diskretisieren:



Wahrscheinlichkeitsverteilung

Thema 1: Was ist Inferenzstatistik?

Prof. Sauer

renzstatistik?

Regression und Inferenz

Klassische vs. Bayes-Inferenz

Wahrscheinlichkeit

Verteilungen

Hinwei

Eine Wahrscheinlichkeitsverteilung des Merkmals X ordnet jeder der k Ausprägungen X=x eine Wahrscheinlichkeit p zu. So hat die Variable *Geschlecht eines Babies* die beiden Ausprägungen $M\ddot{a}dchen$ und Junge mit den Wahrscheinlichkeiten $p_M=51.2\%$ bzw. $p_J=48.8\%$ (Gelman, Hill, und Vehtari 2021).

Bei stetigen Merkmalen geht man von unendlich vielen Ausprägungen aus; die Wahrscheinlichkeit einer bestimmten Ausprägung ist (praktisch) Null: $p(X=x_j)=0, \quad j=1,...,k$. Daher gibt man stattdessen die Dichte der Wahrscheinlichkeit an: Das ist die Wahrscheinlichkeit(smasse) pro eine Einheit von X.

Beispiele für Wahrscheinlichkeitsdichte

Thema 1: Was ist Inferenzstatistik?

Prof. Sauer

Was ist Inferenzstatistik?

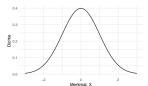
Regression un

Klassische vs. Bayes-Inferenz

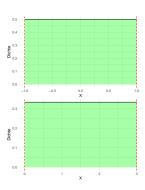
Wahrscheinlichkeit

Verteilungen

Hinweise



Bei X = 0 hat eine Einheit von X die Wahrscheinlichkeitsmasse von 40%.



Bei X = 0 hat eine Einheit von X die Wahrscheinlichkeitsmasse von 50% bzw. 33%.

Gesetz der großen Zahl

Thema 1: Was ist Inferenzstatistik?

Prof. Sauer

Was ist Inferenzstatistik?

Regression ur

Klassische vs. Bayes-Inferenz

Wahrscheinlichkeit

Verteilungen

Hinweise

Zieht man (zufällig) immer mehr Werte aus einer Verteilung², nähert sich der Mittelwert der Stichprobe immer mehr mit dem Mittelwert³ der Verteilung an (Taleb 2019).



²mit endlichem Mittelwert

³oft als Erwartungswert bezeichnet

Normal auf dem Fußballfeld

Thema 1: Was ist Inferenzstatistik?

Prof. Sauer

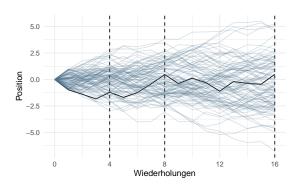
Was ist Inferenzstatistik?

Klassische vs. Bayes-

Inferenz
Wahrscheinlichkeit

Verteilungen

Sie und 1000 Ihrer besten Freunde stehen auf der Mittellinie eines Fußballfelds (eng). Auf Kommando werfen alle jeweils eine Münze; bei Kopf geht man einen Schritt nach links, bei Zahl nach rechts. Das wird 16 Mal wiederholt. Wie wird die Verteilung der Positionen wohl aussehen?



Normal durch Addieren

Thema 1: Was ist Inferenzstatistik?

Prof. Sauer

Was ist Inferenzstatistik?

Regression und

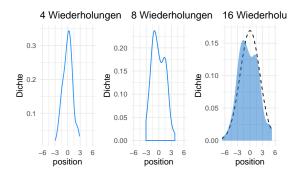
Klassische vs. Bayes-Inferenz

Wahrscheinlichkeit

Verteilungen

Hinweise

Die Summe vieler (gleich starker) Zufallswerte (aus der gleichen Verteilung) erzeugt eine Normalverteilung; egal aus welcher Verteilung die Zufallswerte kommen (Zentraler Grenzwertsatz).



Nicht verwechseln

Thema 1: Was ist Inferenzstatistik?

Prof. Saue

Was ist Inferenzstatistik?

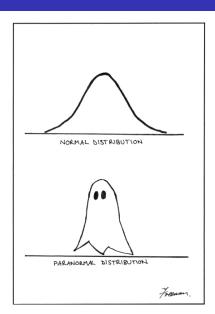
Regression und

Klassische vs. Bayes-Inferenz

Wahrscheinlichkeit

Verteilungen

Hinweise

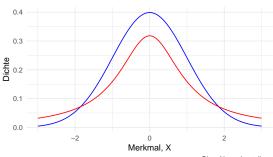


Normalverteilung vs. randlastige Verteilungen

Thema 1: Was ist Inferenzstatistik?

Wahrscheinlichkeit

Verteilungen



Blau: Normalverteilung Rot: randlastige Verteilung (t-Verteilung mit df=1)

Bei randlastigen Verteilungen ("fat tails") kommen Extremereignisse viel häufiger vor als bei Normalverteilungen. Deshalb ist es wichtig sein, zu wissen, ob eine Normalverteilung oder eine randlastige Verteilung vorliegt. Viele statistische Methoden sind nicht zuverlässig bei (stark) randlastigen Methoden (Taleb 2019).

51 / 63

Beispiele für Normal- und randlastige Verteilungen

Thema 1: Was ist Inferenzstatistik?

Prof. Sau

/as ist Infenzstatistik?

Regression un

Klassische vs. Bayes-Inferenz

Wahrscheinlichkeit

Verteilungen

Hinweise

Normal verteilt

- Größe
- Münzwürfe
- Gewicht
 - IQ
- Blutdruck
- Ausschuss einer Maschine

Randlastig verteilt

- Vermögen
- Verkaufte Bücher
- Ruhm
- Aktienkurse
- Erdbeben
- Pandemien
- Kriege
- Erfolg auf Tinder
- Meteroritengröße
- Stadtgrößen

Münzen werfen als Baum: nach 2 Würfen

Thema 1: Was ist Inferenzstatistik?

Prof. Sauer

Was ist Inferenzstatistik?

Regression und

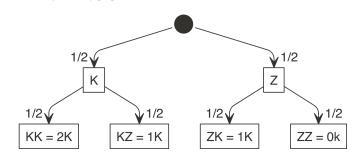
Klassische vs. Bayes-Inferenz

Wahrscheinlichkeit

Verteilungen

Hinweise

Wir zählen, wie oft Kopf (K) geworfen wird: \begin{figure}[H]



Münzen werfen als Baum: nach 3 Würfen

Thema 1: Was ist Inferenzstatistik?

Prof. Sauer

Was ist Inferenzstatistik?

Klassische vs. Bayes-

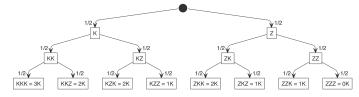
Wahrscheinlichkeit

Verteilungen

Hinweise

Wir zählen, wie oft Kopf (K) geworfen wird:

 $\begin{figure}[H]$



Verteilung nach 3 Münzwürfen

Thema 1: Was ist Inferenzstatistik?

Prof Sauer

Was ist Inferenzstatistik?

Regression und

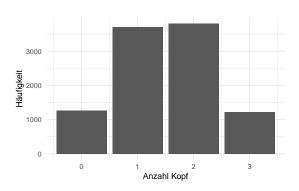
Klassische vs. Bayes-Inferenz

Wahrscheinlichkeit

Verteilungen

Hinweise

Wir werfen sehr oft 3 Münzen:



Verteilung nach 10 Münzwürfen

Thema 1: Was ist Inferenzstatistik?

Prof Sauer

Was ist Inferenzstatistik?

Regression un

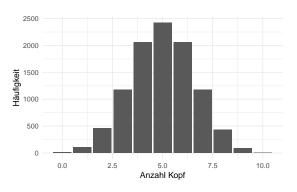
Klassische vs. Bayes-Inferenz

Wahrscheinlichkeit

Verteilungen

Hinweise

Wir werfen sehr oft (10^4 mal) 10 Münzen und zählen jeweils die Anzahl der Treffer (Kopf):



Extreme Trefferzahlen sind selten; mittlere Trefferzahlen häufiger.

Verteilung nach 20 Münzwürfen

Thema 1: Was ist Inferenzstatistik?

Prof Sauer

Was ist Inferenzstatistik?

Regression ur

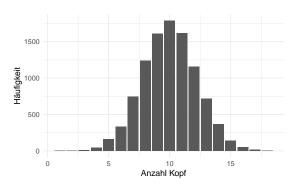
Klassische vs. Bayes-Inferenz

Wahrscheinlichkeit

Verteilungen

Hinweis

Wir werfen sehr oft (10^4 mal) 20 Münzen und zählen jeweils die Anzahl der Treffer (Kopf):



Extreme Trefferzahlen sind selten; mittlere Trefferzahlen häufiger.

Münzen werfen mit R

Thema 1: Was ist Inferenzstatistik?

Wahrscheinlichkeit

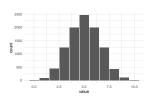
Verteilungen

10 Mal 1 Münze werfen

```
rbinom(10, 1, 1/2)
    [1] 1 1 0 0 0 1 1 0 0 0
```

10000 Mal 10 Münzen werfen

```
muenzvert <-
  rbinom(1e04, 10, .5) %>%
  as tibble()
ggplot(muenzvert,
       aes(x = value)) +
  geom_bar()
```



Definition

Thema 1: Was ist Inferenzstatistik?

Prof. Sauer

renzstatistik?

Inferenz

Klassische vs. Bayes-Inferenz

Wahrscheinlichkeit

Verteilungen

Hinwei

Die Binomialverteilung beschreibt die Anzahl der Treffer (z.B. "Kopf") in einer Serie von gleichartigen und unabhängen Versuchen, die genau zwei mögliche Ergebnisse haben ("Treffer" vs. "Niete").

Einsatzmöglichkeiten: Münzwürfe (Kopf/Zahl), Geburten (Mädchen/Junge), Zustand (ok/defekt), Diagnose (krank/gesund), Jobentscheidung (einstellen/nicht), Finanzinvestion (kaufen/nicht) . . .

Wahrscheinlichkeit berechnen mit R

Thema 1: Was ist Inferenzstatistik?

Prof. Saue

renzstatistik?

Inferenz

Klassische vs. Bayes-Inferenz

Wahrscheinlichkeit

Verteilungen

Hinweise

Ein Prof. stellt einen Klausur mit 20 Richtig-Falsch-Fragen. Wie groß ist die Wahrscheinlichkeit, durch bloßes Münze werfen genau 15 Fragen richtig zu raten?⁴

$$dbinom(x = 15, size = 20, prob = .5)$$

[1] 0.01478577

⁴Hey, endlich mal was für echte Leben!

Thema 1: Was ist Inferenzstatistik?

Prof. Saue

Was ist Inferenzstatistik

Regression und

Klassische vs. Bayes-Inferenz

Wahrscheinlichkeit

Verteilungen

Hinweise

Hinweise

Lehrbuch und Homepage des Lehrbuchs

Thema 1: Was ist Inferenzstatistik?

Prof. Sauei

Was ist Inferenzstatistik?

Klassische vs. Bayes-Inferenz

Wahrscheinlichkeit

Verteilungen

Hinweise

Dieses Skript bezieht sich auf folgende Lehrbücher:

- Kapitel 1 aus Gelman, Hill, und Vehtari (2021), Regression and other Stories (mit "ROS" abgekürzt)
- Kapitel 1 aus McElreath (2016) ("ReThink_v1")
- Rechenregeln sind z.B. in Cramer und Nešlehová (2015)
 (Kap. 3) oder ähnlichen Lehrbüchern nachzulesen.

Weitere Literaturhinweise sind am Ende der jeweiligen Kapitel der Lehrbücher zu finden.

R-Code zum Buch ROS findet sich auf der Homepage des Buchs.

Literatur

Thema 1: Was ist Inferenzstatistik?

FIOI. Saue

Vas ist Infe-

Regression II

Klassische

vs. Bayes-Inferenz

Wahrscheinlichkeit

Verteilungen Hinweise Briggs, William M. 2016. Uncertainty: The Soul of Modeling, Probability & Statistics. Springer.

Cramer, Erhard, und Johanna Nešlehová. 2015. Vorkurs Mathematik. Berlin, Heidelberg: Springer Berlin Heidelberg. https://doi.org/10.1007/978-3-662-46400-7.

Freeman, Matthew. 2006. "A Visual Comparison of Normal and Paranormal Distributions". Journal of Epidemiology and Community Health 60 (1): 6. https://www.ncbi.nlm.nih.gov/pmc/articles/PMC2465539/.

Gelman, Andrew, Jennifer Hill, und Aki Vehtari. 2021. Regression and Other Stories. Analytical Methods for Social Research. Cambridge: Cambridge University Press.

McElreath, Richard. 2016. Statistical Rethinking. 1. Aufl. New York City, NY: CRC Press.

Sauer, Sebastian. 2019. Moderne Datenanalyse mit R: Daten einlesen, aufbereiten, visualisieren und modellieren. 1. Auflage 2019. FOM-Edition. Wiesbaden: Springer. https://www.springer.com/de/book/9783658215866.

Taleb, Nassim Nicholas. 2019. The Statistical Consequences of Fat Tails, Papers and Commentaries. Monograph. https://nassimtaleb.org/2020/01/final-version-fat-tails/.